

【本日アジェンダ】

- ・ 研究の問題設定/ 方向性について
- ・ テンソル変換のモデル説明
- ・ 実験

■研究の問題設定・方向性について

研究テーマ：テンソルを用いたマルチモーダル学習

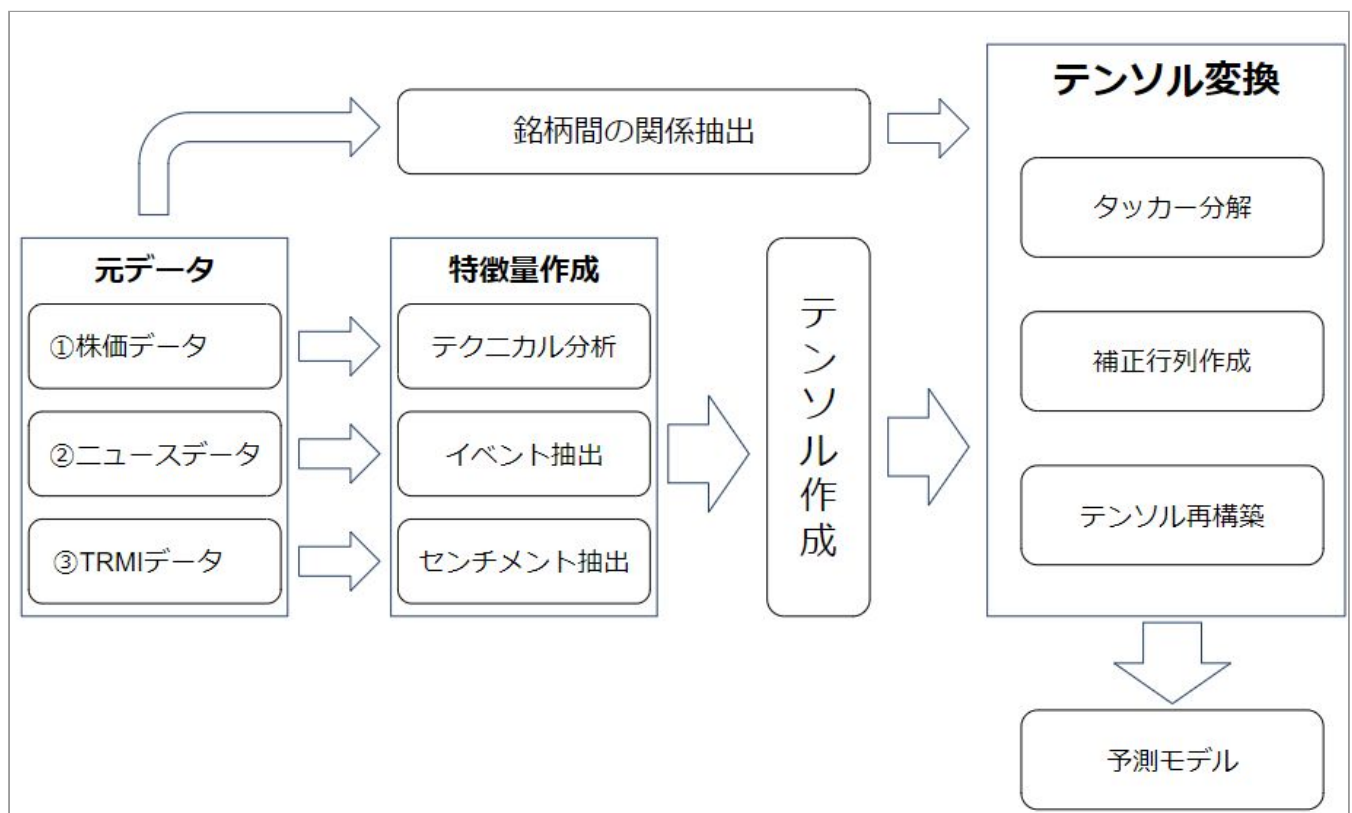
研究内容：

- ・ テンソル変換を用いた前学習
- ・ テンソルベースの予測

モチベーション

- ・ モーダル間の情報を捉える
- ・ モーダルごとに異なるサンプル頻度にうまく対処できる

全体像



■テンソル変換の説明

銘柄 s の時刻 t におけるテンソル（株価データ、ニュースデータ、センチメントデータ）を $\mathcal{X}_{s,t}$ とする。

$\mathcal{X}_{s,t}$ の各要素を $x_{i,j,k}^{s,t}$ とすると、（株価データ、ニュースデータ、センチメントデータ）は次のように入っている。

$$\begin{aligned} x_{i,1,1}^{s,t}, 1 \leq i \leq I_1 &: \text{株価データの特徴量} \\ x_{2,j,2}^{s,t}, 1 \leq j \leq I_2 &: \text{ニュースデータの特徴量} \\ x_{3,3,k}^{s,t}, 1 \leq k \leq I_3 &: \text{センチメントデータの特徴量} \\ \text{それ以外は} &0 \end{aligned}$$

このテンソルは以下のようにタッカー分解することができる。

$$\mathcal{X}_{s,t} = \mathcal{C}_{s,t} \times_1 U_1^{s,t} \times_2 U_2^{s,t} \times_3 U_3^{s,t}$$

最終的に欲しいもの

$$\hat{\mathcal{X}}_{s,t} = \mathcal{C}_{s,t} \times_1 (V_{s,1}^T U_1^{s,t}) \times_2 (V_{s,2}^T U_2^{s,t}) \times_3 (V_{s,3}^T U_3^{s,t})$$

$\mathcal{X}_{s,t} \in R^{I_1 \times I_2 \times I_3}$: 銘柄 s , 時刻 t のテンソル

$\mathcal{C}_{s,t} \in R^{D_1 \times D_2 \times D_3}$: 銘柄 s , 時刻 t のテンソルをタッカー分解したときのコアテンソル

$U_k^{s,t} \in R^{I_k \times D_k}$: 銘柄 s , 時刻 t のテンソルをタッカー分解したときのファクター k

$V_{s,k} \in R^{I_k \times J_k}$ ($J_k \leq I_k$) : 銘柄 s のファクター k の補助行列

この V_k を得るための最適化式について

①銘柄内補完

$$\begin{aligned} \min_{V_{s,k}} J(V_{s,k}) &= \frac{\mu}{\text{sum} W_s} \sum_{i=1}^T \sum_{j=1}^T \|V_{s,k}^T U_k^{s,i} - V_{s,k}^T U_k^{s,j}\|^2 w_{s,i,j} \\ &+ \frac{1}{\text{sum} W_s} \sum_{i=1}^T \sum_{j=1}^T \|V_{s,k}^T U_k^{s,i} - I_{s,k} U_k^{s,j}\|^2 w_{s,i,j} \end{aligned}$$

$$w_{s,i,j} = \begin{cases} 1 & (\text{時刻 } i, j \text{ が } \hat{\mathcal{X}} \text{ の結果が似ている場合}) \\ 0 & (\text{その他}) \end{cases} \quad (W_s \text{ は対称行列})$$

$$\text{sum} W_s = \sum_{i=1}^T \sum_{j=1}^T w_{s,i,j}$$

$$V_{s,k} = \text{sum} W_s \left(\frac{2\mu + 1}{\text{sum} W_s} D_{U_k^s} - \frac{2\mu}{\text{sum} W_s} W_{U_k^s} \right)^{-1} D_{U_k^s}$$

$$d_{s,i} = \sum_{j=1}^T w_{s,i,j} = \sum_{m=1}^T w_{s,m,i}$$

$$D_{U_k^s} = \sum_{i=1}^T d_{s,i} U_k^{s,i} U_k^{s,iT}, \quad W_{U_k^s} = \sum_{i=1}^T \sum_{j=1}^T w_{i,j} U_k^{s,i} U_k^{s,jT}$$

②関連銘柄間の補完

$$\min_{V_{s,k}} J(V_{s,k}) = \frac{\gamma}{\text{sum}E_s} \sum_{t=1}^T \sum_{m=1}^C \|V_{s,k}^T U_k^{s,t} - V_{s,k}^T U_k^{m,t}\|^2 z_{s,m} e_{s,t,m} \quad (68)$$

$$+ \frac{1}{\text{sum}W_s} \sum_{i=1}^T \sum_{j=1}^T \|V_{s,k}^T U_k^{s,i} - I_{s,k} U_k^{s,j}\|^2 w_{s,i,j} \quad (69)$$

$$e_{s,t,m} = \begin{cases} 1 & (\text{時刻 } t \text{ の銘柄 } s, m \text{ のデータがある場合}) \\ 0 & (\text{その他}) \end{cases} \quad (70)$$

$$z_{s,m} : \text{銘柄 } s \text{ と } m \text{ の関連度 (Z は対称行列)} \quad (71)$$

$$\text{sum}E_s = \sum_{i=1}^T \sum_{m=1}^C e_{s,t,m} \quad (72)$$

$$V_{s,k} = \text{sum}W_s \left(\frac{1}{\text{sum}W_s} D_{U_k^s} + \frac{\gamma}{\text{sum}E_s} (A_k^s + 2B_k^s + C_k^s) \right)^{-1} D_{U_k^s} \quad (73)$$

$$A_k^s = \sum_{t=1}^T \sum_{m=1}^C U_k^{s,t} U_k^{s,tT} e_{s,t,m} z_{s,m}, \quad B_k^s = \sum_{t=1}^T \sum_{m=1}^C U_k^{s,t} U_k^{m,tT} e_{s,t,m} z_{s,m}, \quad C_k^s = \sum_{t=1}^T \sum_{m=1}^C U_k^{m,t} U_k^{m,tT} e_{s,t,m} z_{s,m}$$

③銘柄内・関連銘柄間の補完

$$\begin{aligned} \min_{V_{s,k}} J(V_{s,k}) &= \frac{\mu}{\text{sum}W_s} \sum_{i=1}^T \sum_{j=1}^T \|V_{s,k}^T U_k^{s,i} - V_{s,k}^T U_k^{s,j}\|^2 w_{s,i,j} \\ &+ \frac{\gamma}{\text{sum}E_s} \sum_{t=1}^T \sum_{m=1}^C \|V_{s,k}^T U_k^{s,t} - V_{s,k}^T U_k^{m,t}\|^2 z_{s,m} e_{s,t,m} \\ &+ \frac{1}{\text{sum}W_s} \sum_{i=1}^T \sum_{j=1}^T \|V_{s,k}^T U_k^{s,i} - I_{s,k} U_k^{s,j}\|^2 w_{s,i,j} \end{aligned}$$

$$V_{s,k} = \text{sum}W_s \left(\frac{2\mu + 1}{\text{sum}W_s} D_{U_k^s} - \frac{2\mu}{\text{sum}W_s} W_{U_k^s} + \frac{\gamma}{\text{sum}E_s} (A_k^s + 2B_k^s + C_k^s) \right)^{-1} D_{U_k^s}$$

□w_{s,i,j} の種類

- ・ Up : 時刻 i, j のResidual Returnが共に正の場合
- ・ Down : 時刻 i, j のResidual Returnが共に負の場合

□Z_{s,m}の種類

①終値の値動きの方向性の一致度

- N_{s,m} : 銘柄s, mの終値が共に上昇・下落した日数
- M : 全取引日数
- Z_{s,m} = N_{s,m} / M

②ResidualReturnでの動きの方向性の一致度

③終値の変化率のピアソン相関係数

④Residual Returnのピアソン相関係数

(⑤記事の中の共起度合)

■実験

前回の総合ゼミまでの結果は、コードミスで正確な実験ができていませんでした。
今実験をやり直していますが、今回は実験の一部のみ報告します。

【問題設定】

(前日の15:30 , 今日の15:30] のデータを利用して、今日の16:00の終値のResidual Returnが上昇・下落するかを予測

・予測対象

NY証券取引所に上場されている**2業界13銘柄**(景気連動型消費財6社、生活必需品4社、素材7社)

※ニュースの数が多い企業を選択

・使用データと取得のタイミング

	項目	データ期間	データ取得のタイミング
株価データ	終値、出来高、%K、RSI	2013 - 2019年	NY時間 16:00
ニュースデータ	ニュースタイトルの単語をword2vecで分散表現(300次元)。PCAで20次元に減らす	2006 - 2019年	グリニッジ標準時間 ニュースが出たタイミング
TRMI	sentiment、buzz、emotionVsFact	1998 - 2019年	NY時間 15:30

※NY証券取引所の取引時間はNY時間 9:30~16:00 サマータイム等を考慮して、**すべてのデータをNY時間に合わせる**

・予測期間

トレーニング : 2013 - 2017年

テスト : 2018 - 2019年

・予測モデル

ランダムフォレスト

今までの実験では、3つのデータソースがそろっている日のみをpick upして実験を行っていた。
今回からは、株価データ+(ニュースデータ or TRMI)のデータがある日をpick upして実験を行う。
nullはトレーニングデータを使って、平均で埋める。

⇒ **実験のデータ数が増える & より実用的**

■テンソル補完で前処理 VS 前処理なし

①銘柄内補完

実験未完了

②関連銘柄間の補完

実験未完了

③銘柄内・関連銘柄間の補完

300					
テンソル補完	あり				なし
μ, γ, W, Z	0.1, 1, Up, ②	0.1, 1, Up, ③	0.1, 1, Down, ②	0.1, 1, Down, ③	-
素材	0.5576	0.5556	0.5564	0.5554	0.5161
景気連動型消費財	0.5031	0.5009	0.4995	0.4991	0.4953
All	0.5324	0.5303	0.5302	0.5294	0.5065

20					
テンソル補完	あり				なし
μ, γ, W, Z	0.1, 1, Up, ②	0.1, 1, Up, ③	0.1, 1, Down, ②	0.1, 1, Down, ③	-
素材	0.5510	0.5520	0.5509	0.5507	0.5293
景気連動型消費財	0.5045	0.5037	0.5067	0.5034	0.5025
All	0.5295	0.5297	0.5305	0.5289	0.5169

前処理としてテンソル補完をしたら精度がよかった。

■今後の予定

- ・上記の追加の実験の実施
- ・テンソル補完はデータが不足している日の予測に強い？
⇒テストデータをデータが不足している日にしてみての実験
- ・企業間の類似度を、記事内の共起度合にする
- ・テンソルベースの予測モデルでの実験